

BTYT Banking Analytics — Fundamentos Matemáticos y Estadísticos

Proyecto: Banco de Treinta y Tres (BTYT) Banking Analytics Tipo de documento: Especificación matemática viva y referencia de estudio Estado: Activo — se actualiza a medida que los generadores se refactorizan y congelan Fase actual: Refactor de arquitectura de la Parte I, antes de la generación canónica a gran escala Última actualización: 2026-09-03

1. Propósito y alcance

Este documento registra los fundamentos matemáticos, probabilísticos, estadísticos, temporales y contables de BTYT.

Es una especificación matemática viva. Su objetivo no es decorar el proyecto con notación matemática, sino hacer explícitos los mecanismos que realmente gobiernan el universo bancario sintético.

A lo largo del documento se distinguen tres niveles de formalización:

- Implementado: confirmado por el código de producción de BTYT.
- Conceptual: representación matemática de un principio de diseño implementado, aunque el código Python lo exprese de forma procedural y no mediante exactamente la ecuación mostrada.
- Planificado: matemática prevista para una fase posterior, pero todavía no implementada.

Nunca debe presentarse un modelo de manual como si fuera un mecanismo implementado en BTYT si el código no lo utiliza realmente.

El principio central de modelado es:

BTYT modela las causas como desplazamientos probabilísticos del comportamiento, no como asignaciones determinísticas de resultados. Condiciones causales compartidas pueden influir sobre múltiples procesos, pero las realizaciones posteriores utilizan flujos estocásticos independientes.

PARTE A — NOTACIÓN MATEMÁTICA GLOBAL

2. Notación de índices

Se prefieren los siguientes índices en BTYT.

Símbolo	Significado
i	Cliente o entidad individual genérica
a	Cuenta
b	Banco
r	Sucursal
l	Préstamo

Símbolo	Significado
c	Campaña o categoría, según el contexto
k	Producto, segmento, categoría o estado discreto genérico
t	Período temporal
m	Mes
y	Año
n	Mundo Monte Carlo / índice de simulación
j	Flujo RNG o índice secundario genérico
N	Tamaño de población o muestra

Cuando un símbolo pueda ser ambiguo, la sección correspondiente lo define explícitamente.

3. Notación griega preferida

Símbolo	Interpretación preferida en BTYT
π	Probabilidad asociada a un evento modelado
μ	Media, nivel basal o nivel de largo plazo
σ	Desviación estándar o volatilidad
σ^2	Varianza
ϕ	Persistencia temporal / coeficiente autorregresivo
λ	Intensidad o tasa de eventos
α	Intercepto, efecto basal o efecto de entidad
β	Sensibilidad o coeficiente principal
γ	Sensibilidad o coeficiente secundario
δ	Efecto estructural adicional
θ	Sensibilidad a shocks o interacciones
ρ	Correlación o parámetro de dependencia
ε	Innovación idiosincrática / perturbación aleatoria
η	Perturbación latente adicional o shock específico
ω	Peso
τ	Umbral temporal o momento de un evento
κ	Umbral, escala o concentración cuando sea necesario

Estas convenciones reducen la notación arbitraria y facilitan la extensión de la especificación matemática.

PARTE B — PROBABILIDAD Y GENERACIÓN ESTOCÁSTICA

4. Variables aleatorias y realizaciones

Sea X una variable aleatoria y x uno de sus valores realizados.

Un mecanismo estocástico genérico se escribe:

$$X \sim F(\boldsymbol{\theta})$$

donde:

- F es una distribución de probabilidad;
- $\boldsymbol{\theta}$ es su vector de parámetros.

Por lo tanto, un generador de BTYT define un mecanismo que produce una realización del mundo, en lugar de limitarse a asignar una colección fija de valores.

5. Eventos Bernoulli

Para un evento binario asociado a la entidad i :

$$Y_i \mid \pi_i \sim \text{Bernoulli}(\pi_i)$$

con:

$$P(Y_i = 1) = \pi_i$$

y:

$$P(Y_i = 0) = 1 - \pi_i$$

donde:

$$0 \leq \pi_i \leq 1$$

Esta estructura general es relevante para eventos estocásticos como cierres, fallas, respuestas a campañas, degradación operacional y otras realizaciones binarias.

6. Probabilidad condicional y heterogeneidad

BTYT evita, en general, asignar la misma probabilidad a todas las entidades.

En cambio:

$$\pi_{i,t} = P(Y_{i,t} = 1 \mid \mathbf{x}_{i,t}, \mathbf{z}_t)$$

donde:

- $\mathbf{x}_{i,t}$ contiene información específica de la entidad;
- $\mathbf{z}_t$ contiene condiciones compartidas en el período t .

Por lo tanto:

$$\pi_{i,t} \neq \pi_{j,t}$$

puede cumplirse para dos entidades distintas en el mismo período.

Asimismo:

$$\pi_{i,t} \neq \pi_{i,t+1}$$

puede cumplirse para la misma entidad a lo largo del tiempo.

7. Desplazamientos causales probabilísticos

Supongamos una probabilidad basal π_0 .

Una especificación latente aditiva conceptual puede representarse como:

$$\pi_{i,t}^* = \pi_0 + \alpha_i + \beta_{k(i)} + \gamma_t + \delta_{g(i)} + \theta S_t + \varepsilon_{i,t}$$

donde:

- α_i = efecto individual;
- $\beta_{k(i)}$ = efecto del producto o segmento;

- γ_t = efecto temporal;
- $\delta_{\{g(i)\}}$ = efecto geográfico;
- S_t = shock sistémico;
- θ = sensibilidad al shock;
- $\varepsilon_{\{i,t\}}$ = componente idiosincrático.

Si esta representación se utiliza directamente como probabilidad, debe acotarse:

$$\pi_{i,t} = \min(1, \max(0, \pi_{i,t}^*))$$

Esta ecuación es conceptual salvo que un generador específico confirme su uso exacto. Algunos generadores de BTYT utilizan ajustes multiplicativos, pesos normalizados u otras transformaciones.

El invariante es el principio causal:

$$S_t \Rightarrow \Delta \pi_{i,t}$$

pero no:

$$S_t \Rightarrow Y_{i,t} = 1$$

8. Distribuciones categóricas ponderadas

Para una variable categórica X_i que puede tomar uno de K estados:

$$X_i \sim \text{Categorical}(\omega_1, \omega_2, \dots, \omega_K)$$

sujeto a:

$$\omega_k \geq 0$$

y:

$$\sum_{k=1}^K \omega_k = 1$$

Esta es la estructura matemática genérica detrás de las selecciones ponderadas entre alternativas discretas.

PARTE C — RNG Y REPRODUCIBILIDAD

9. Generación pseudoaleatoria con semilla

Sea s la semilla canónica.

Una secuencia pseudoaleatoria puede representarse como:

$$\mathcal{R} = G(s)$$

donde G es el generador pseudoaleatorio.

Para la misma implementación:

$$s_1 = s_2 \implies \mathcal{R}_1 = \mathcal{R}_2$$

siempre que el algoritmo y el orden de las extracciones aleatorias permanezcan sin cambios.

10. Flujos estocásticos independientes

Para el flujo j :

$$\mathcal{R}_j = G(s, j)$$

El objetivo de j es separar procesos estocásticos conceptualmente diferentes.

Idealmente:

$$\mathcal{R}_j \perp \mathcal{R}_k \quad j \neq k$$

en el sentido práctico de diseño: los procesos posteriores consumen flujos determinísticos separados derivados de la semilla común del mundo.

Esto sostiene el principio de BTYT:

causas compartidas + realizaciones independientes

11. Requisito de invariancia respecto al chunk

Sea:

$$\mathcal{W}(s, \mathbf{c}, h)$$

el mundo realizado con:

- semilla s ;
- configuración del mundo $\mathbf{c}$;
- tamaño técnico de chunk h .

El invariante deseado es:

$$\mathcal{W}(s, \mathbf{c}, h_1) = \mathcal{W}(s, \mathbf{c}, h_2)$$

para tamaños válidos h_1 y h_2 .

Por lo tanto:

El tamaño del chunk es un parámetro de ingeniería, no un parámetro estadístico.

La implementación exacta necesaria para garantizar este invariante se establecerá durante el refactor de los generadores.

PARTE D — DINÁMICA TEMPORAL

12. Variables longitudinales

Una variable que cambia en el tiempo a nivel de entidad se escribe:

$$X_{i,t}$$

mientras que una variable de todo el sistema se escribe:

$$X_t$$

Según el subsistema, t puede representar una fecha, un mes o un año.

13. Persistencia autorregresiva

Un proceso persistente estándar de primer orden es:

$$X_t - \mu = \phi(X_{t-1} - \mu) + \varepsilon_t$$

o, de forma equivalente:

$$X_t = (1 - \phi)\mu + \phi X_{t-1} + \varepsilon_t$$

donde:

- μ = nivel de largo plazo;
- ϕ = persistencia;
- ε_t = innovación.

En el caso AR(1) estacionario convencional:

$$|\phi| < 1$$

Esta notación es útil para las dinámicas tipo AR de mercado y macroeconomía de BTYT. Las ecuaciones exactas reemplazarán las formas conceptuales cuando los generadores queden congelados.

14. Innovaciones y volatilidad

Una hipótesis general para la innovación puede escribirse:

$$\varepsilon_t \sim F(0, \sigma^2)$$

y, cuando la implementación utilice específicamente una innovación gaussiana:

$$\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$$

No debe suponerse la forma gaussiana salvo que el código la confirme.

15. Shocks compartidos

Sea S_t un shock sistémico.

Un estado a nivel de entidad puede representarse conceptualmente como:

$$X_{i,t} = \mu_{i,t} + \beta_i S_t + \varepsilon_{i,t}$$

donde:

- β_i = exposición o sensibilidad;
- $\varepsilon_{\{i,t\}}$ = innovación idiosincrática.

Dos entidades pueden experimentar el mismo shock de manera diferente:

$$\beta_i \neq \beta_j$$

16. Efectos de interacción

Si el efecto de X_1 depende de X_2 , un término de interacción genérico es:

$$\beta_3 X_1 X_2$$

dentro de un modelo conceptual como:

$$Y = \alpha + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 + \varepsilon$$

Esta notación representa el concepto de interacción y no implica que BTYT estime necesariamente una regresión lineal para el generador correspondiente.

PARTE E — MATEMÁTICA DEL MERCADO BANCARIO

17. Simplex de participaciones de mercado

Sea:

$$\omega_{b,t}$$

la participación de mercado del banco b en el período t .

Entonces:

$$\omega_{b,t} \geq 0$$

y:

$$\sum_{b=1}^B \omega_{b,t} = 1$$

El vector:

$$\boldsymbol{\omega}_t = (\omega_{1,t}, \dots, \omega_{B,t})$$

pertenece, por lo tanto, al simplex de probabilidad:

$$\boldsymbol{\omega}_t \in \Delta^{B-1}$$

Esta restricción de normalización es estructural.

18. Límites específicos por banco

Sea:

$$\ell_b$$

el límite inferior plausible del banco b , y:

$$u_b$$

su límite superior.

Entonces:

$$\ell_b \leq \omega_b \leq u_b$$

El margen disponible o *headroom* es:

$$h_b = u_b - \ell_b$$

Una preferencia normalizada basada en ese margen es:

$$q_b = \frac{h_b}{\sum_{j=1}^B h_j}$$

con:

$$\sum_b q_b = 1$$

Esta notación corresponde al concepto de normalización por margen disponible utilizado durante la calibración del mercado bancario.

19. Posición bancaria latente dinámica

Una representación conceptual útil de la posición latente del banco b es:

$$z_{b,t} = \mu_b + \phi_b(z_{b,t-1} - \mu_b) + \beta_b M_t + \gamma_b S_t + \varepsilon_{b,t}$$

donde:

- μ_b = posición de largo plazo específica del banco;
- ϕ_b = persistencia;
- M_t = estado común de mercado o macroeconómico;
- β_b = sensibilidad al estado común;
- S_t = shock;
- γ_b = sensibilidad al shock;
- $\varepsilon_{\{b,t\}}$ = innovación específica del banco.

Las participaciones realizadas deben luego satisfacer las restricciones del simplex y los límites correspondientes.

La transformación exacta desde el estado latente hasta $\omega_{\{b,t\}}$ se documentará a partir del generador bancario definitivo.

PARTE F — AUDITORÍA MONTE CARLO

20. Mundos simulados

Sean:

$$\mathcal{W}^{(1)}, \mathcal{W}^{(2)}, \dots, \mathcal{W}^{(N)}$$

N mundos simulados utilizados para auditoría.

Para una estadística X :

$$\bar{X} = \frac{1}{N} \sum_{n=1}^N X^{(n)}$$

21. Probabilidad empírica de un evento

Sea $\mathbb{1}(A)$ la función indicadora:

$$\mathbb{1}(A) = \begin{cases} 1, & A \text{ ocurre} \\ 0, & A \text{ no ocurre} \end{cases}$$

Entonces:

$$\hat{P}(A) = \frac{1}{N} \sum_{n=1}^N \mathbb{1}(A_n)$$

Ejemplos:

- un banco termina primero;
- un banco entra en el top 3;
- se alcanza un límite;
- una sucursal cierra;
- falla una regla de control.

22. Cuantiles empíricos

Para una estadística simulada X , BTYT utiliza cuantiles como:

$$Q_{0.05}(X), \quad Q_{0.50}(X), \quad Q_{0.95}(X)$$

correspondientes a P05, mediana y P95.

Estos describen el rango de mundos plausibles y no únicamente la realización canónica.

PARTE G — MATEMÁTICA DE SUCURSALES

23. Cierres estocásticos

Para la sucursal r :

$$C_r \mid \pi_r^{(C)} \sim \text{Bernoulli}(\pi_r^{(C)})$$

donde:

$C_r = \begin{cases} 1, & \text{la sucursal cierra} \\ 0, & \text{la sucursal permanece abierta} \end{cases}$

y:

$$\pi_r^{(C)} = f(\mathbf{x}_r, \mathbf{z}_t)$$

depende de las características de la sucursal y de las condiciones del mundo.

Un shock puede producir:

$$\pi_{r, \text{shock}}^{(C)} > \pi_{r, \text{baseline}}^{(C)}$$

sin obligar a que:

$$C_r = 1$$

24. Número de cierres por mundo

Para el mundo simulado n :

$$K^{(n)} = \sum_{r=1}^R C_r^{(n)}$$

La auditoría Monte Carlo examina la distribución empírica:

$$\hat{P}(K = k)$$

así como las frecuencias de cierre específicas por sucursal:

$$\hat{\pi}_r^{(C)} = \frac{1}{N} \sum_{n=1}^N C_r^{(n)}$$

PARTE H — CLIENTES Y RELACIONES DE PRODUCTOS

25. Generación jerárquica

El universo bancario sintético contiene relaciones condicionales, no tablas planas independientes.

Conceptualmente:

$$Customer_i \rightarrow Account_{i,a} \rightarrow Card_{i,a,k}$$

y:

$$(Customer_i, Account_{i,a}, Product_k) \rightarrow Loan_{i,l}$$

Por lo tanto:

$$P(A_{i,a} \mid X_i)$$

y:

$$P(L_{i,l} \mid X_i, A_{i,a}, P_k)$$

pueden depender del estado generado previamente.

Esta estructura jerárquica crea heterogeneidad económicamente significativa para los análisis posteriores.

PARTE I — MATEMÁTICA DEL CRÉDITO

26. Identidad stock-flujo del préstamo

Sean:

- $B_{l,t}$ = saldo del préstamo;
- $I_{l,t}$ = interés devengado;
- $P_{l,t}$ = reducción por principal/pago;
- $A_{l,t}$ = otros ajustes explícitamente modelados.

Una evolución genérica del saldo es:

$$B_{l,t} = B_{l,t-1} + I_{l,t} - P_{l,t} + A_{l,t}$$

La implementación específica por producto se documentará cuando los generadores de crédito queden congelados.

27. Déficit de pago

Sea:

$$S_{l,t}$$

el pago programado y:

$$A_{l,t}^{(pay)}$$

el pago efectivamente realizado.

Entonces:

$$H_{l,t} = \max(0, S_{l,t} - A_{l,t}^{(pay)})$$

donde $H_{l,t}$ es el déficit de pago.

28. Estado de morosidad

Sea:

$$d_{l,t} \geq 0$$

la cantidad de días de atraso.

Un estado de morosidad puede representarse como:

$$D_{l,t} = g(d_{l,t})$$

donde g transforma los días de atraso en categorías de riesgo.

Los umbrales exactos de BTYT se incorporarán a partir de la implementación definitiva del ciclo de vida crediticio.

29. Default estocástico

Para el préstamo l :

$$Y_l^{(D)} \mid \pi_l^{(D)} \sim \text{Bernoulli}(\pi_l^{(D)})$$

con:

$$\pi_l^{(D)} = f(\mathbf{x}_l, \mathbf{p}_l, \mathbf{h}_{l,t}, \mathbf{m}_t, \mathbf{s}_{l,t})$$

donde las entradas pueden representar características del cliente, información del producto/originación, comportamiento histórico, condiciones macroeconómicas y shocks.

El requisito esencial es:

$$0 < \pi_l^{(D)} < 1$$

en los casos no degenerados.

Las características de riesgo deben modificar la probabilidad de default, no determinarlo perfectamente.

30. Conjunto de información y fuga de información

Para una predicción realizada en t , definimos:

$$\mathcal{I}_t$$

como el conjunto de información disponible en ese momento.

Una característica válida debe satisfacer:

$$X \in \mathcal{I}_t$$

La información futura:

$$X_{t+h}, \quad h > 0$$

no debe entrar al conjunto de variables explicativas si revela información que todavía no estaba disponible al momento de predecir.

Esta es la base formal para evitar *target leakage* en la Parte II.

PARTE J — MATEMÁTICA DE TRANSACCIONES Y SALDOS

31. Flujo transaccional con signo

Para la cuenta a y el período t :

$$F_{a,t} = I_{a,t} - O_{a,t}$$

donde:

- $I_{a,t}$ = entradas completadas;
- $O_{a,t}$ = salidas completadas.

32. Reconciliación de saldos

Sean:

- $B_{a,t}^{(0)}$ = saldo inicial;
- $B_{a,t}^{(1)}$ = saldo final.

Entonces:

$$B_{a,t}^{(1)} = B_{a,t}^{(0)} + I_{a,t} - O_{a,t} + A_{a,t}$$

donde $A_{a,t}$ contiene únicamente ajustes explícitamente modelados fuera de los flujos transaccionales ordinarios.

Cuando no existen esos ajustes:

$$B_{a,t}^{(1)} = B_{a,t}^{(0)} + I_{a,t} - O_{a,t}$$

Esta es una identidad contable, no una expectativa estadística.

33. Continuidad de saldos

Para períodos consecutivos:

$$B_{a,t+1}^{(0)} = B_{a,t}^{(1)}$$

salvo límites de ciclo de vida de la cuenta explícitamente modelados.

34. Transferencias internas

Para una transferencia de monto $q > 0$ desde la cuenta a hacia la cuenta b:

$$\Delta B_a = -q$$

y:

$$\Delta B_b = +q$$

Por lo tanto:

$$\Delta B_a + \Delta B_b = 0$$

para el principal de la transferencia.

Esta es la identidad de conservación detrás de la reconciliación de transferencias internas.

35. Transacciones fallidas

Para una transacción fallida de monto nominal q , la propia transacción no debe generar el efecto de saldo de una operación completada:

$$Status = FAILED \implies \Delta B^{(q)} = 0$$

sujeto a cualquier comisión o efecto operacional modelado por separado.

36. Intensidad del conteo de transacciones

Una notación genérica para el proceso de conteo es:

$$N_{a,t} \sim C(\lambda_{a,t}, \boldsymbol{\theta})$$

donde:

- C = mecanismo real de conteo;
- $\lambda_{a,t}$ = intensidad de actividad;
- $\boldsymbol{\theta}$ = parámetros adicionales.

Conceptualmente:

$$\lambda_{a,t} = \lambda_a \cdot s_t \cdot m_{a,t}$$

donde:

- λ_a = intensidad basal de la cuenta;
- s_t = efecto estacional;
- $m_{a,t}$ = multiplicador conductual o macroeconómico.

La notación evita deliberadamente afirmar una distribución Poisson hasta confirmar el mecanismo exacto del generador definitivo de transacciones.

37. Evolución de canales

Para el uso de canales digitales:

$$\pi_{i,t}^{(digital)} = P(Channel_{i,t} = Digital)$$

y para el uso de efectivo:

$$\pi_{i,t}^{(cash)} = P(Channel_{i,t} = Cash)$$

Estas probabilidades pueden evolucionar como:

$$\pi_{i,t}^{(digital)} = f(t, \mathbf{x}_i, \mathbf{z}_t)$$

y:

$$\pi_{i,t}^{(cash)} = g(t, \mathbf{x}_i, \mathbf{z}_t)$$

permitiendo adopción digital y transición del efectivo heterogéneas a lo largo del tiempo.

PARTE K — MATEMÁTICA DE SHOCKS EXTERNOS

38. Descomposición entre shock sistémico e idiosincrático

Sea:

$$S_t$$

el shock sistémico y:

$$\eta_{i,t}$$

un shock idiosincrático.

Un estado combinado puede representarse como:

$$Z_{i,t} = S_t + \eta_{i,t}$$

La agregación exacta de producción puede diferir y se documentará a partir del generador definitivo.

39. Exposición y resiliencia

Sean:

- $e_{i,t}$ = exposición;
- $r_{i,t}$ = resiliencia;
- $Z_{i,t}$ = estado del shock.

Una función conceptual de impacto es:

$$\Psi_{i,t} = Z_{i,t} \cdot e_{i,t} \cdot (1 - r_{i,t})$$

donde una mayor resiliencia reduce el impacto efectivo.

Esta notación es conceptual salvo que el generador congelado utilice exactamente esta transformación.

40. Estructura causal entre sistemas

Un shock común puede influir sobre varias probabilidades:

$$\pi_{i,t}^{(D)} = f_D(\mathbf{x}_{i,t}, S_t)$$

$$\pi_{i,t}^{(A)} = f_A(\mathbf{x}_{i,t}, S_t)$$

$$\pi_{r,t}^{(C)} = f_C(\mathbf{x}_{r,t}, S_t)$$

donde los superíndices pueden representar default, actividad y cierre.

Sin embargo:

$$Y_{i,t}^{(D)}, \quad Y_{i,t}^{(A)}, \quad Y_{r,t}^{(C)}$$

siguen siendo realizaciones estocásticas separadas.

Por lo tanto, una causa común no implica resultados idénticos.

PARTE L — MATEMÁTICA DE CAMPAÑAS

41. Elegibilidad, exposición y respuesta

Para el cliente i y la campaña c , definimos:

- $E_{i,c}$ = elegibilidad;
- $X_{i,c}$ = exposición;
- $R_{i,c}$ = respuesta.

La secuencia lógica es:

$$E_{i,c} \rightarrow X_{i,c} \rightarrow R_{i,c}$$

Para tiempos de respuesta atribuida:

$$\tau_{i,c}^{(R)} \geq \tau_{i,c}^{(X)}$$

42. Probabilidad de respuesta

Condicional a la exposición:

$$R_{i,c} \mid X_{i,c} = 1 \sim \text{Bernoulli}(\pi_{i,c}^{(R)})$$

donde:

$$\pi_{i,c}^{(R)} = f(\mathbf{x}_i, \mathbf{c}, \text{channel}, \text{geography}, \text{time}, \text{behavior}, \text{external state})$$

La segmentación modifica la probabilidad de respuesta; no asigna determinísticamente la respuesta.

43. Tasa de respuesta

Si:

$$N_c^{(X)} = \sum_i X_{i,c}$$

y:

$$N_c^{(R)} = \sum_i R_{i,c}$$

entonces:

$$RR_c = \frac{N_c^{(R)}}{N_c^{(X)}}$$

para $N_c^{(X)} > 0$.

Las tasas condicionales pueden calcularse de forma análoga por canal, geografía, segmento u otras dimensiones.

PARTE M — CONFIABILIDAD DE DATOS OPERACIONALES

44. Probabilidad de degradación

Para el registro i :

$$Q_i \mid \pi_i^{(Q)} \sim \text{Bernoulli}(\pi_i^{(Q)})$$

donde:

$$\pi_i^{(Q)} = f(\text{incident}, \text{system}, \text{time}, \text{reliability level}, \text{record characteristics})$$

Por lo tanto:

$$\text{Incident} = \mathcal{X} \Rightarrow Q_i = 1$$

sino:

$$Incident = 1 \Rightarrow \Delta\pi_i^{(Q)}$$

45. Verdad sintética y observación operacional

Sea:

$$X_i^*$$

la verdad sintética y:

$$\widetilde{X}_i$$

el valor observado operacionalmente.

Para variables protegidas:

$$\widetilde{X}_i = X_i^*$$

Para metadatos degradables:

$$\widetilde{X}_i = D(X_i^*, Q_i)$$

donde $\mathcal{D}$ es el operador de degradación.

Esta distinción formal permite que BTYT conozca el estado sintético verdadero y, al mismo tiempo, modele datos operacionales imperfectos.

PARTE N — MATEMÁTICA DE VALIDACIÓN

46. Integridad referencial

Sea $\mathcal{P}$ el conjunto de claves padre válidas.

Para toda clave foránea requerida f_i :

$$f_i \in \mathcal{P}$$

El número de claves inválidas es:

$$N_{FK}^{invalid} = \sum_{i=1}^N \mathbb{1}(f_i \notin \mathcal{P})$$

Un PASS estricto requiere:

$$N_{FK}^{invalid} = 0$$

47. Unicidad de clave primaria

Para la clave primaria k_i :

$$|\{k_1, \dots, k_N\}| = N$$

o, de forma equivalente:

$$N_{PK}^{duplicate} = 0$$

48. Integridad temporal

Para eventos causalmente ordenados:

$$\tau_1 \leq \tau_2$$

Por ejemplo:

$$\tau^{origination} \leq \tau^{payment}$$

y:

$$\tau^{exposure} \leq \tau^{response}$$

Los eventos del ciclo de vida también deben ocurrir dentro del intervalo válido de existencia de la entidad correspondiente.

49. Residuos de reconciliación

Sean:

- O_i = valor observado;
- E_i = valor implicado por una identidad contable o estructural.

Definimos el residuo:

$$e_i = O_i - E_i$$

Residuo absoluto:

$$|e_i|$$

Máximo residuo absoluto:

$$e_{\max} = \max_i |e_i|$$

Para identidades exactas, el objetivo es:

$$e_{\max} = 0$$

salvo una tolerancia explícitamente aceptada por precisión de punto flotante.

50. Momentos descriptivos

Para observaciones $x_1, \dots, x_N$:

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

Varianza muestral:

$$s^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2$$

Desviación estándar muestral:

$$s = \sqrt{s^2}$$

Estas estadísticas complementan los cuantiles y frecuencias empíricas en la auditoría de generadores.

PARTE O — MATEMÁTICA DE ESCALA Y RENDIMIENTO

51. Throughput

Para R filas generadas durante un tiempo transcurrido T:

$$\nu = \frac{R}{T}$$

donde ν es el throughput, normalmente medido en filas por segundo.

52. Escalamiento de población y tiempo de ejecución

Para dos ejecuciones de benchmark:

$$\chi_N = \frac{N_2}{N_1}$$

y:

$$\chi_T = \frac{T_2}{T_1}$$

Si:

$$\chi_T \approx \chi_N$$

el tiempo de ejecución es aproximadamente lineal respecto a la población de clientes dentro del intervalo observado.

Esto debe medirse empíricamente.

53. Escalamiento computacional empírico

Una relación útil para benchmarks es:

$$T(N) \approx \alpha N^\beta$$

Tomando logaritmos:

$$\ln T = \ln \alpha + \beta \ln N$$

Interpretación:

$$\beta \approx 1$$

sugiere escalamiento aproximadamente lineal;

$$\beta > 1$$

sugiere escalamiento superlineal;

$$\beta < 1$$

sugiere escalamiento sublineal dentro del rango medido.

Aquí β describe escalamiento computacional y no debe confundirse con coeficientes conductuales utilizados en otras secciones.

54. Proyección de almacenamiento

Para un tamaño observado S_1 a escala N_1 , una primera proyección es:

$$\widehat{S}_2 = S_1 \frac{N_2}{N_1}$$

cuando el almacenamiento escala aproximadamente de forma lineal con la población relevante.

Para tablas de transacciones puede ser mejor proyectar según el número de filas:

$$\widehat{S}_{tx, 2} = S_{tx, 1} \frac{R_{tx, 2}}{R_{tx, 1}}$$

en lugar de utilizar solamente la cantidad de clientes.

55. Compresión

Para tamaño CSV $S_{\{CSV\}}$ y tamaño Parquet $S_{\{PQ\}}$:

$$K_{comp} = \frac{S_{CSV}}{S_{PQ}}$$

es la razón de compresión.

La reducción relativa de almacenamiento es:

$$\delta_{storage} = 1 - \frac{S_{PQ}}{S_{CSV}}$$

Estas cantidades se medirán durante la escalera de pruebas y no se asumirán de antemano.

PARTE P — PARTE II: MATEMÁTICA DEL CREDIT SCORING

56. Estado

Las siguientes secciones contienen fundamentos matemáticos planificados para la Parte II. Deben ampliarse y marcarse como implementadas únicamente cuando los modelos correspondientes sean efectivamente desarrollados.

57. Variable objetivo binaria

Sea:

$Y_i = \begin{cases} 1, & \text{default} \\ 0, & \text{no default} \end{cases}$

El objetivo de modelado es estimar:

$$\pi_i^{(D)} = P(Y_i = 1 \mid \mathbf{x}_i)$$

58. Regresión logística

Si se mantiene la regresión logística:

$$\pi_i = \frac{1}{1 + \exp(-z_i)}$$

con:

$$z_i = \beta_0 + \sum_{j=1}^K \beta_j x_{ij}$$

Los odds son:

$$\mathcal{O}_i = \frac{\pi_i}{1 - \pi_i}$$

y:

$$\ln \mathcal{O}_i = \beta_0 + \sum_{j=1}^K \beta_j x_{ij}$$

Por lo tanto:

$$e^{\beta_j}$$

es el cambio multiplicativo en los odds asociado a un aumento de una unidad en x_j , manteniendo constantes las demás variables explicativas.

59. Umbral de clasificación

Dada una probabilidad predicha $\hat{\pi}_i$ y un umbral τ :

$$\hat{Y}_i = \mathbb{1}(\hat{\pi}_i \geq \tau)$$

El umbral es un parámetro de decisión y no tiene por qué ser igual a 0.5.

En riesgo crediticio, su selección debe considerar los costos relativos de falsos positivos y falsos negativos.

60. Métricas de la matriz de confusión

Sean:

- TP = verdaderos positivos;
- TN = verdaderos negativos;
- FP = falsos positivos;
- FN = falsos negativos.

Entonces:

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$Specificity = \frac{TN}{TN + FP}$$

$$F_1 = 2 \frac{Precision \cdot Recall}{Precision + Recall}$$

La exactitud, si se utiliza, es:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

pero no debe interpretarse de forma aislada, especialmente cuando existe desbalance de clases.

61. ROC y AUC

Para el umbral τ :

$$TPR(\tau) = \frac{TP(\tau)}{TP(\tau) + FN(\tau)}$$

y:

$$FPR(\tau) = \frac{FP(\tau)}{FP(\tau) + TN(\tau)}$$

La curva ROC representa:

$$TPR(\tau) \text{ contra } FPR(\tau)$$

a través de diferentes umbrales.

ROC-AUC puede interpretarse, bajo la interpretación estándar de puntajes continuos, como la probabilidad de que una observación positiva elegida al azar reciba un puntaje mayor que una observación negativa elegida al azar.

62. Calibración

Un modelo probabilístico está calibrado cuando:

$$P(Y = 1 \mid \hat{\pi} = p) \approx p$$

En la práctica, esto se evalúa sobre intervalos de probabilidad y no exige probabilidades repetidas exactamente iguales.

En riesgo crediticio, la calibración importa porque la probabilidad predicha tiene significado económico.

63. Brier score

Para la probabilidad predicha $\hat{\pi}_i$:

$$BS = \frac{1}{N} \sum_{i=1}^N (\hat{\pi}_i - Y_i)^2$$

Valores menores indican mejor precisión probabilística.

64. Puente hacia pérdida crediticia esperada

Si BTYT extiende posteriormente el análisis de riesgo más allá de la probabilidad de default, una descomposición bancaria natural es:

$$ECL = PD \times LGD \times EAD$$

donde:

- PD = probabilidad de default;
- LGD = pérdida dado el default;
- EAD = exposición al momento del default.

Esto no forma parte actualmente de la implementación comprometida de la Parte II. Se registra únicamente como posible extensión matemática futura si el alcance del proyecto lo justifica.

PARTE Q — GOBERNANZA MATEMÁTICA

65. Ecuaciones exactas frente a conceptuales

Cada ecuación de este documento debe terminar clasificada como una de las siguientes:

Exacta

El generador de producción implementa el mecanismo expresado.

Equivalente

La implementación es procedural, pero la ecuación es matemáticamente equivalente.

Conceptual

La ecuación explica el diseño, pero no constituye el algoritmo exacto de producción.

Planificada

El mecanismo pertenece a una fase futura.

A medida que avance el refactor, las secciones conceptuales deberán reemplazarse por especificaciones exactas o equivalentes siempre que sea posible.

66. Protocolo de congelamiento de generadores

Cuando un generador quede congelado:

1. inspeccionar el código final de producción;
2. identificar cada variable aleatoria;
3. identificar su distribución o mecanismo real de extracción;
4. identificar transformaciones determinísticas;

5. identificar recurrencias temporales;
6. identificar normalizaciones y límites;
7. identificar dependencias e interacciones;
8. identificar los flujos RNG;
9. identificar restricciones contables y relacionales duras;
10. identificar las estadísticas de auditoría;
11. actualizar este documento.

Esto crea una relación directa:

implementación Python $\leftrightarrow$ especificación matemática

67. Tres capas matemáticas de BTYT

BTYT combina tres formas distintas de estructura matemática.

Capa 1 — Identidades duras

Deben cumplirse.

Por ejemplo:

$$B_{a,t}^{(1)} = B_{a,t}^{(0)} + I_{a,t} - O_{a,t}$$

y:

$$\sum_b \omega_{b,t} = 1$$

Capa 2 — Estructura estocástica

Define probabilidades y distribuciones.

Por ejemplo:

$$Y_{i,t} \sim \text{Bernoulli}(\pi_{i,t})$$

y:

$$\pi_{i,t} = f(\mathbf{x}_{i,t}, \mathbf{z}_t)$$

Capa 3 — Estructura dinámica

Genera persistencia y condiciones que evolucionan en el tiempo.

Por ejemplo:

$$X_t - \mu = \phi(X_{t-1} - \mu) + \varepsilon_t$$

y:

$$X_{i,t} = \mu_{i,t} + \beta_i S_t + \varepsilon_{i,t}$$

La credibilidad de BTYT surge de combinar las tres:

Consistencia contable y relacional dura + comportamiento estocástico heterogéneo + dinámica temporal coherente.

68. Objetivo de largo plazo del documento

Cuando la Parte I de BTYT quede congelada, este documento debería ser suficientemente preciso para que una persona con formación técnica pueda comprender:

- qué es aleatorio;
- qué es determinístico;
- qué está condicionado por qué;
- qué procesos comparten causas;
- qué realizaciones permanecen independientes;
- cómo entra el tiempo al sistema;
- qué identidades deben cumplirse exactamente;
- cómo se auditan estadísticamente los generadores.

Cuando la Parte II esté terminada, el mismo documento debería explicar además:

- cómo se construye el objetivo crediticio;
- qué información está disponible al momento de predecir;
- cómo se definen las variables explicativas;
- cómo los modelos estiman el riesgo;
- cómo se miden discriminación y calibración;

- cómo se comparan y registran los experimentos.

El objetivo final no es la complejidad matemática por sí misma.

Es hacer que el banco sintético sea matemáticamente legible, reproducible y auditable.